

Павло Мриглоцький. Рев'ю ОГЛЯД МЕТОДІВ АНАЛІЗУ

Вступ

Наукова стаття «ОГЛЯД МЕТОДІВ АНАЛІЗУ ДАНИХ ТА МЕТОДІВ МАШИННОГО НАВЧАННЯ ПРИ ПРОГНОЗУВАННІ ІШЕМІЧНОЇ ХВОРОБИ СЕРЦЯ» досліджує методи побудови прогностичних кластеризаційних моделей для прогнозування Ішемічної Хвороби Серця на основі датасетів з різними симптомами та цільовою змінною реальної класифікації.

Дослідження зосереджено на наступних питаннях:

1. Особливості підбору даних
2. Особливості первинної обробки даних
3. Аналіз ефективності різних моделей кластеризації для задач прогнозування Ішемічної Хвороби серця

Основною метою дослідження можемо назвати знаходження оптимальної моделі прогнозування ішемічної хвороби серця, котра б найточніше прогнозувала її.

Методологія

Первинний пошук інформації

При пошуку інформації про домейн автори скористалися сервіс з пошуку наукової інформації **Semantic Scholar** (<https://www.semanticscholar.org>). У публікації детально обговорюється методологія запитів, що була використана для знаходження необхідних матеріалів про домейн.

Автори наголошують на важливості пізнання домейну дослідження Data Science, аби правильно обробити дані та приблизно уявити розподіл даних між ознаками.

Аналіз моделей кластеризації

Даний аналіз проводився з двох сторін:

1. На основі інших наукових публікацій
2. На основі математичного аналізу самих моделей

На початку автори проходяться по використаннях різних моделей кластеризації в різних наукових дослідженнях. Вони вважають, що вживаність тієї чи іншої моделі показує реальну її наукову вартість. Для мене ж це – не показник.

Більш реалістичний критерій ефективності моделі для мене є вимірювання метрик ефективності. У публікації для вимірювання ефективності моделі використовуються такі метрики:

- Accuracy
- F1 Score
- Precision
- Recall/Sensitivity
- Specificity

Власне такі метрики можуть показати реальну корисність моделі.

Результати

Найкращі моделі

З публікації випливає, що найпопулярнішою моделлю згідно з частотою вживання у наукових дослідженнях є **Модель Опорних Векторів**. З іншого боку, найточнішою виявилася ансамблева модель **XGBoost**.

Важливість попередньої обробки даних

В публікації показано важливість попередньої обробки даних. Найнебезпечнішими аномаліями в даних показано:

1. Викиди
2. Аномалії
3. Відсутні значення

Для покращення становища рекомендується:

1. Стандартизація даних
2. Заповнення прогалин у даних
3. Інженерія ознак

Ключові інсайти

Важливість знання предметної області

З публікації я зрозумів, що для правильної оцінки даних, обробки, та правильної підготовки важливим є знання предметної області.

Це дозволить:

- Правильно зрозуміти знаки
- Підібрати правильну стратегію стандартизації та заповнення відсутніх даних
- Дасть уявлення про розподіл даних, що в свою чергу дозволить добре підібрати оптимальну модель.

Попередня обробка даних важлива

Попередня обробка даних дуже важлива для точності прогнозів. І справа не лише в стандартизації даних чи заповненні пропущених даних але й в правильній інженерії ознак.

Висновок

Наукова стаття «ОГЛЯД МЕТОДІВ АНАЛІЗУ ДАНИХ ТА МЕТОДІВ МАШИННОГО НАВЧАННЯ ПРИ ПРОГНОЗУВАННІ ІШЕМІЧНОЇ ХВОРОБИ СЕРЦЯ» ставить важливу проблему дослідження даних для прогнозування медичних діагнозів. Ця галузь дуже чутлива до точності, адже ціна питання – життя людей. З іншого боку, це ж і дуже перспективна галузь для Data Science, котра матиме, на мою думку, достатньо замовлень і бюджету для роботи.