

Павло Мриглоцький. Рев'ю ПОРІВНЯННЯ АЛГОРИТМІВ КЛАСТЕРИЗАЦІЇ

Вступ

Наукова публікація «ПОРІВНЯННЯ АЛГОРИТМІВ КЛАСТЕРИЗАЦІЇ ДАНИХ» Дорошенко І.В., Кнігніцька Т.В., Крештанович М.А. розглядає різні алгоритми кластеризації на основі різних розподілів даних. Головним предметом дослідження є ефективність роботи того чи іншого алгоритму на різних розподілах даних. Стаття розглядає зарівно як і принципи роботи алгоритмів кластеризації, так і про результати дослідження результатів кожного з них.

Методологія

Аналіз

Автори проводять дослідження у двох вимірах:

1. Алгоритми кластеризації
2. Розбиття даних

У статті розглядають наступні алгоритми:

- K-Means
- Hierarchical Agglomerative Clustering (HAC)
- Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
- Expectation–Maximization clustering using Gaussian Mixture Models (GMM)

Експерименти проводились на наступних видах розбиттів даних:

- концентричні кола
- смужки
- хмари
- нероздільна множина
- серпи

Кожен алгоритм кластеризації проводився на кожному розбитті. Для кожного розбиття порівнювалась ефективність кластеризації всіх перерахованих алгоритмів.

Репрезентація і ілюстративність

В аналізованій нами статті як розбиття, так і результати кластеризації подавались графічно. Це дуже покращує візуальність результатів, котрі базуються на векторах. Основою візуалізації є двовимірна точкова візуалізація кожного вектора, як точки. Це інтуїтивно унаочнювало, які приблизно кластери мали розбиття представлені розбиття.

Результати роботи алгоритмів кластеризації представлялись зафарбовуванням точок на розбитті у різні кольори, котрі репрезентували певний кластер. Це дає можливість легко оцінити результат роботи алгоритму, скільки візуально на розбитті видно, які мали б бути реальні кластери.

Результати

Згідно із результатами дослідження, проведеного у публікації, впливає, що найефективнішими моделями кластеризації є DBSCAN та HAC. Всі інші алгоритми справляються добре із специфічними розбиттями даних.

Ключові інсайти

Результативність алгоритма кластеризації залежить від розподілу даних

Як бачимо, на різних розподілах даних різні алгоритми дають добрі результати. Попри те, що DBSCAN показав себе найкраще на більшості розподілах, ми бачимо конкретно, що результативність багатьох алгоритмів кластеризації напряду залежить від особливостей розбиття даних. Наприклад, алгоритм KMeans гарно працює на наборі даних з невеликим розкидом але зовсім не працює на наборах даних з горизонтальною кластеризацією.

Ресурс Shiny Apps

Дуже корисний ресурс для моделювання розбиття певного розподілу даних на оптимальну кількість кластерів. Адреса ресурсу: shinyapps.io. Варто спробувати у своїй подальшій роботі.

Висновок

В науковій публікації Дорошенко І.В., Кнігніцька Т.В., Крештанович М.А. «ПОРІВНЯННЯ АЛГОРИТМІВ КЛАСТЕРИЗАЦІЇ ДАНИХ» було проведено аналіз роботи кількох алгоритмів кластеризації на наборах даних з різною розбивкою даних. Було показано, що ефективність роботи алгоритму кластеризації часто залежить від структури самих даних. Дуже корисним було застосування механізму візуалізації як самих даних, так і результатів кластеризації.